전자공학종합설계 2
주간 진행보고

CICIoT2023 기반 MLP 양자화 및 RF 경량화 검증

2026 년 11 월 9 일

보고서 구성

1 장은 MLP 의 동적 INT8 양자화 방법·비교 설정·결과를, 2 장은 기존 RF 경량화와 학습량을 맞춘 50:50 추가 검증을 다룬다. 각 장에서 수행 내용, 설정 이유, 결과의 의미를 순서대로 확인할 수 있도록 구성했다.

목차

1. MLP 양자화 2
- 1.1 적용 대상과 양자화 방법 2
- 1.2 비교 설정과 검증 가설 2
- 1.3 FP32·INT8 결과 비교 2
- 1.4 결과 해석: 크기·속도·가중치 범위 3
- 1.5 결론과 재현 방법 3

2. RF 경량화 4
- 2.1 수행 내용과 설정 이유 4
- 2.2 기존 경량화 결과와 의미 4
- 2.3 50 만:50 만 추가 검증을 설계한 이유 5
- 2.4 추가 검증 결과 5
- 2.5 정량적 의미와 최종 판단 6

읽는 기준

MLP 의 F1·Precision·Recall 은 원문에 명시된 weighted average 다. RF 의 종합 성능은 macro F1 로 보고하고 클래스별 지표를 별도로 표시했다. 두 장의 F1 숫자와 서로 다른 컴퓨터의 추론 시간을 직접 비교해 모델 우열을 판단하지 않는다.

1. MLP 양자화

1.1 적용 대상과 양자화 방법

대상: LightweightMLP_IDS (전부 nn.Linear 3 개 층으로 구성 — hidden1(d→128), embedding(128→64), classifier(64→C)). 재학습 없이, 학습 끝난 모델의 Linear 층만 int8 로 변환하는 dynamic post-training quantization(torch.quantization.quantize_dynamic(..., {nn.Linear}, dtype=torch.qint8)) 적용. 데이터: CICIoT2023 PCAP binary (DDoS vs Benign).

1.2 비교 설정과 검증 가설

비교 변수 2 개를 독립적으로 바꿔가며 4 가지 조합 실험: 1. feature 수: baseline(38 개, 전체) vs rf_top5(RF 기준 top-5, 5 개) 2. 클래스 비율: 원본 불균형(DDoS:Benign ≈ 95:5) vs 1:1 balanced(DDoS 를 Benign 개수만큼 undersampling, train 에만 적용 — test 는 항상 원본 불균형 분포 그대로 평가) 평가지표는 전부 weighted average (precision_recall_fscore_support(..., average="weighted")), test set 은 모든 설정에서 동일(6,297,039 행, Benign 329,362 / DDoS 5,967,677).

처음엔 "DDoS:Benign 95:5 불균형이 quantization 손실(-4pp)의 원인"이라는 가설을 세우고 baseline 을 balanced 로 재학습해 검증 → 가설 확인: 손실이 -4.16pp → -1.06pp 로 약 75% 감소.

1.3 FP32·INT8 결과 비교

설정	Params	FP32 Acc / F1	INT8 Acc / F1	Accuracy Δ	F1 Δ
baseline 38 특징·불균형	13,762	0.9889 / 0.9893	0.9473 / 0.9236	-4.16pp	-6.57pp
rf_top5 5 특징·불균형	9,538	0.9877 / 0.9882	0.9477 / 0.9222	-4.00pp	-6.60pp
baseline 38 특징·balanced	13,762	0.9867 / 0.9873	0.9761 / 0.9752	-1.06pp	-1.21pp
rf_top5 5 특징·balanced·seed1	9,538	0.9845 / 0.9854	0.1240 / 0.1899	-86.05pp	-79.55pp
rf_top5 5 특징·balanced·seed2	9,538	0.9847 / 0.9856	0.0523 / 0.0052	-93.24pp	-98.04pp

설정	크기 변화 (FP32→INT8)	추론 (µs/표본)	속도 배율
baseline 38 특징·불균형	57.5→20.9KB (-63.7%)	0.87→0.92	0.94x
rf_top5 5 특징·불균형	41.0→16.8KB (-59.1%)	1.76→1.54	1.15x
baseline 38 특징·balanced	57.5→20.9KB (-63.7%)	3.69→3.41	1.08x
rf_top5 5 특징·balanced·seed1	41.0→16.8KB (-59.1%)	4.84→5.61	0.86x
rf_top5 5 특징·balanced·seed2	41.0→16.8KB (-59.1%)	3.74→6.83	0.55x

(속도 수치는 모델이 너무 작아 측정 노이즈 수준이라 방향이 설정마다 뒤집힘 — 아래 "속도 관련" 참고)

1.4 결과 해석: 크기·속도·가중치 범위

핵심 발견 1 — 크기 감소는 항상 안정적

모든 설정에서 59~64% 크기 감소. 이건 quantization 자체가 작동한다는 걸 보여주는 가장 신뢰도 높은 효과.

핵심 발견 2 — 속도 비교는 이 모델 규모에서 신뢰 불가

FLOPs 가 17,920~26,368 수준으로 워낙 작아 forward pass 자체가 마이크로초 단위(0.87~6.83μs)라, quantize/dequantize 변환 오버헤드가 int8 연산 이득과 비슷하거나 더 큼. 같은 아키텍처(rf_top5)인데 불균형(1.15x 빨라짐) vs balanced(0.86x, 0.55x 느려짐)에서 방향조차 안 맞아, 속도는 "모델 속성"이 아니라 측정 노이즈로 봐야 함.

핵심 발견 3 — Accuracy 손실의 진짜 원인: weight 크기 ≠ 클래스 불균형 단독이 아님

같은 검증을 rf_top5 에도 적용했더니 정반대 결과: balanced 로 바꾸자 오히려 손실이 -4.00pp → -86~93pp 로 폭발적으로 악화 (seed 2 개에서 재현 확인, 우연 아님). 조사 결과:

설정	hidden1 weight abs_max	hidden1 weight std
baseline (balanced)	11.44	0.69
rf_top5 (balanced, seed1)	47.80	6.60
rf_top5 (balanced, seed2)	35.77	5.12

rf_top5 의 weight 가 baseline 보다 절댓값 3~4 배, 표준편차 8~10 배 큼 (embedding/classifier 층도 동일 패턴). Dynamic INT8 은 weight 전체 범위를 256 단계로 고정 분할하는데, weight 범위가 4 배 넓으면 양자화 1 단계 간격도 4 배 거칠어져 미세한 weight 차이가 전부 뭉개짐.

weight 가 왜 커지는지: feature 가 5 개뿐이면 38 개일 때와 같은 신호 크기를 만들기 위해 각 feature 가 훨씬 큰 weight 를 가져야 하고, balanced 학습(다수 클래스로 도망칠 지름길이 없어짐)은 모델이 좁은 5 차원 공간에서 더 날카로운 결정 경계를 만들도록 압박해 weight 를 더 극단적으로 키운 것으로 추정.

INT8 결과 자체도 이를 뒷받침: accuracy 0.0523 은 정확히 test set 의 Benign 비율(5.23%)과 일치 — quantized 모델이 입력과 무관하게 거의 전부 "Benign"으로만 찍는 완전 degenerate 분류기가 됐다는 뜻 (weighted F1 도 "전부 Benign" 가정으로 역산한 값과 정확히 일치).

1.5 결론과 재현 방법

1. Dynamic INT8 quantization 은 모델 크기를 안정적으로 59~64% 줄이지만, 속도 이득은 이 모델 규모에서 보장되지 않는다.

2. Accuracy 손실의 크기는 "파라미터 수"가 아니라 "학습된 weight 의 동적 범위(dynamic range)"에 좌우된다. feature 수가 적을수록, 그리고 class-balanced 학습으로 결정 경계가 날카로워질수록 weight 가 커지고, 이것이 per-tensor int8 의 고정 해상도를 압도해 양자화 손실을 비선형적으로 키울 수 있다 — 최악의 경우 (rf_top5 + balanced) 모델이 완전히 degenerate 한 단일 클래스 분류기로 붕괴했다.

3. 실무적 함의: edge 경량화를 위해 "feature 수를 줄이고(rf_top5 등) + 클래스 불균형도 해소"하는 두 최적화를 동시에 적용하는 건 위험할 수 있다 — 개별적으로는 각각 합리적인 선택이지만 조합하면 quantization 안정성을 크게 해칠 수 있으므로, quantization 을 적용할 계획이라면 각 최적화 조합마다 반드시 사후 검증(validation)이 필요하다.

4. 이번 CICIoT2023 PCAP binary 과제에서는, quantization 이 baseline(38-feature, 불균형 그대로)에서 가장 안전했다(-4.16pp) — feature selection 이나 class balancing 과 결합할 때는 weight 분포를 먼저 점검(inspect_weights.py)한 뒤 적용을 결정하는 것을 권장.

train.py --save_model : 학습된 모델 state_dict + scaler + config 저장

quantize_eval.py : FP32 vs INT8 비교 (accuracy/F1/크기/속도)

balance_classes.py : train CSV 의 다수 클래스를 소수 클래스 개수만큼 undersampling

inspect_weights.py : 저장된 체크포인트의 Linear 층별 weight min/max/abs_max/std 비교

2. RF 경량화

2.1 수행 내용과 설정 이유

목적은 CICIoT2023 에서 정상·DDoS 탐지 성능을 유지하면서 RF 의 저장 크기와 예측 비용을 줄이는 것이다. 기존 특징·트리·깊이 탐색 결과를 정리하고, 학습 데이터의 불균형 때문에 경량화 효과가 왜곡됐는지 확인하기 위해 동일 학습량의 50:50 추가 검증을 수행했다.

데이터는 원본 PCAP 에서 추출한 38 개 특징·비중첩 10 패킷 윈도우다. 지정 캡처의 첫 2GB 청크 중심이며 일부 작은 캡처는 전체를 사용했다. 총 20,990,150 행에서 파일별 시간순 앞 70%를 학습 풀, 뒤 30%를 테스트로 유지했다. 테스트는 정상 329,362 / DDoS 5,967,677, 총 6,297,039 행이다.

변수	탐색 범위	변경 이유
특징 수	5 / 10 / 15 / 20 / 38	입력 정보를 줄였을 때 탐지 성능과 모델 비용이 어떻게 변하는지 확인
트리 수	10 / 20 / 50 / 100	트리 수 감소로 예측 연산과 저장 비용을 줄일 수 있는지 확인
최대 깊이	8 / 12 / 16 / 무제한	트리 분기 수를 제한해 모델 크기를 줄일 때의 성능 손실 확인
최소 리프 표본	1 / 10 / 100	소수 표본에 대한 세밀한 분기를 제한해 트리 복잡도 감소
클래스 가중치	balanced	학습 클래스 빈도의 역수로 가중치를 보정. 정상 표본 수 자체를 늘리는 방법과 구분

위 값은 지정 조합으로 단계별 탐색했으며 모든 조합을 실행한 것은 아니다. 중요도 순위는 기존 학습 RF 에서 얻었다. 기존 설정 비교는 seed 42, 학습 최대 100 만 행을 사용했다. 기기별 학습은 이번 보고서 범위에서 제외한다.

2.2 기존 경량화 결과와 의미

모델 구성	특징 / 트리 / 깊이	Accuracy	Macro F1	MB	µs/표본
기준선	38 / 100 / ∞	0.991985	0.962073	95.19	8.861
38 특징·20 트리	38 / 20 / ∞	0.991690	0.960770	25.44	1.984
38 특징·10 트리	38 / 10 / ∞	0.991385	0.959429	16.73	1.016
15 특징·20 트리	15 / 20 / ∞	0.990756	0.956630	25.62	1.492
38 특징·20 트리·깊이 16	38 / 20 / 16	0.990070	0.953881	9.91	2.426

표는 기존 최종 후보의 동일 시간순 테스트 평가다. 최소 리프 표본은 1 이다. F1 은 두 클래스의 macro F1 이며 MB 는 비압축 RF 객체 크기다. 예측 시간은 당시 측정값이므로 다음 절의 재실행 시간과 직접 섞어 비교하지 않는다.

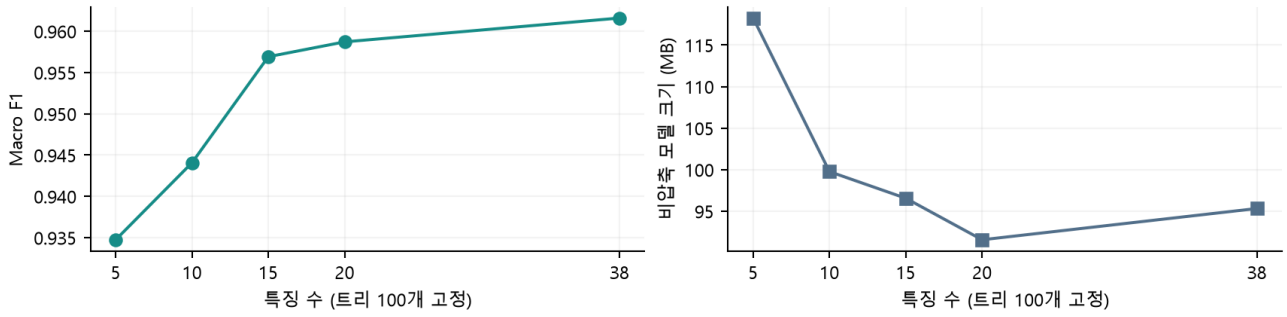


그림 1. 기존 특징 수 탐색 단계 결과. 최종 후보 표와 별도 실행이며 같은 설정도 실행별 차이가 있을 수 있다.

특징 5 개는 38 개보다 macro F1 이 낮고 모델 크기는 오히려 컸다. 입력 차원을 줄여도 RF 가 더 복잡한 트리를 만들 수 있어 특징 수만으로 경량화를 판단하기 어렵다. 반면 38 특징·20 트리 모델은 최종 후보 기준선 대비 macro F1 약 0.1303%p 감소로 모델 크기를 95.19→25.44 MB 로 줄였다. 38 특징·20 트리·깊이 16 모델은 9.91 MB 까지 작아졌지만 macro F1 손실이 더 컸다.

2.3 50 만:50 만 추가 검증을 설계한 이유

기존 학습 100 만 행은 DDoS 약 95%, 정상 약 5%였다. 높은 전체 정확도가 정상 클래스의 손실을 가릴 수 있어, 정상 표본을 더 많이 포함하면 경량 모델의 성능이 개선되는지 확인했다. 총학습량 증가 효과를 섞지 않기 위해 기존 비율과 50:50 모두 100 만 행으로 고정했다.

조건	기존 비율	50:50 학습	이렇게 정한 이유
학습 표본 수	100 만 행	100 만 행	학습량 증가 효과와 클래스 구성 변경을 구분
정상 / DDoS	약 5.2 만 / 94.8 만	50 만 / 50 만	같은 시간순 학습 풀 안에서 중복 없이 재표집
모델 구성	38 특징·100 트리 / 5 특징·100 트리 / 38 특징·20 트리	같은 세 구성	기준선·특징 축소·트리 축소를 고정해 대응 비교
가중치·특징 순위	balanced / 기존 RF 순위	동일	새 특징 선택이나 설정 변경 효과를 섞지 않음
테스트	기존 6,297,039 행	동일한 전체 테스트	평가 분포 변경 없이 학습 구성의 영향 확인
반복	seed 42 / 43 / 44	같은 seed 3 회	한 번의 표본 선택·RF 난수에만 의존하지 않도록 확인

기존 시간순 학습 풀은 14,693,111 행(정상 768,515 / DDoS 13,924,596)이다. 기존 비율 seed 42 의 실제 학습 구성은 정상 52,219 / DDoS 947,781 이었다. 균형군은 정상·DDoS 각 500,000 행이다. 세 구성×두 학습 비율×세 seed 로 총 18 개 모델을 학습했다. 후보를 사전에 고정한 추가 검증으로, 별도 검증 분할이나 새로운 최적 설정 선택을 수행한 것은 아니다.

2.4 추가 검증 결과

학습 구성	특징·트리	Accuracy	Macro F1 ± SD	정상 Recall %	DDoS Recall %	MB	µs/표본
기존 비율	38·100	0.991832	0.961402 ±0.000657	99.35	99.17	94.63	6.408
기존 비율	5·100	0.985472	0.933924 ±0.001521	97.71	98.59	118.57	4.244
기존 비율	38·20	0.991585	0.960317 ±0.000835	99.34	99.15	25.32	1.405
50:50	38·100	0.989019	0.949522 ±0.001088	99.84	98.85	116.62	6.992
50:50	5·100	0.981617	0.919911 ±0.000404	99.28	98.10	152.28	4.195
50:50	38·20	0.989143	0.950038 ±0.000718	99.84	98.86	29.74	1.364

seed 3 회의 평균이며 macro F1 에는 표준편차를 병기했다. 속도는 같은 테스트 10 만 표본에 대해 단일 스레드 RF.predict 를 워밍업 후 5 회 측정한 중앙값의 seed 평균이다. 통계적 유의성 검정 결과는 아니다.

2.5 정량적 의미와 최종 판단

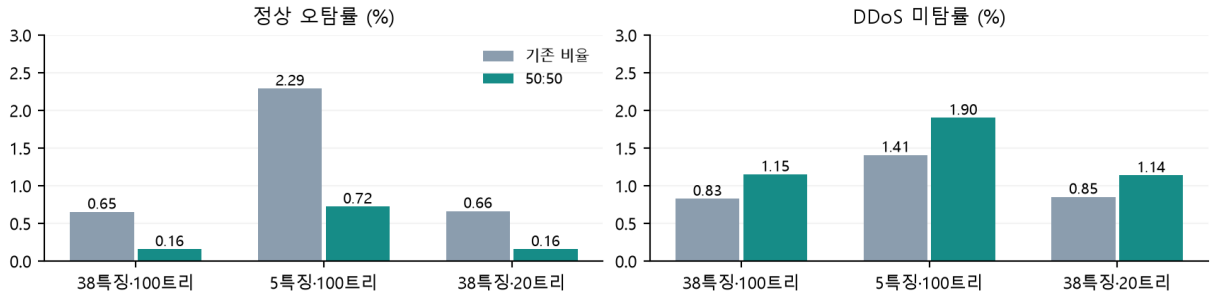


그림 2. 3 회 평균 오탐·미탐률. 정상 오탐률=정상을 DDoS 로 예측한 비율, DDoS 미탐률=DDoS 를 정상으로 예측한 비율이다.

판단 1. 50:50 학습으로 기존 RF 경량화 결과를 전면 교체하지 않는다.

세 구성·세 seed 의 9 개 대응 비교 모두에서 50:50 학습의 정상 Recall 은 높아졌지만 macro F1 은 낮아졌다. 정상 오탐 감소와 DDoS 미탐 증가의 교환관계가 관찰됐다. 정상 데이터를 더 학습하면 모든 지표가 함께 개선될 것이라는 기대는 이번 테스트에서 확인되지 않았다.

구성	Macro F1 차이	정상 Precision 차이	정상 Recall 차이	DDoS Recall 차이
38 특징·100 트리	-1.188	-4.175	+0.495	-0.324
5 특징·100 트리	-1.401	-5.061	+1.567	-0.493
38 특징·20 트리	-1.028	-3.664	+0.506	-0.286

50:50 평균−기존 비율 평균, 단위는 %p. 정상 Precision 도 세 구성 모두 낮아졌다. 정상 Precision 은 정상으로 예측한 결과 중 실제 정상의 비율이며, 실제 정상을 정상으로 맞힌 비율인 정상 Recall 과 다르다.

판단 2. 입력 특징 수보다 실제 트리 복잡도와 예측 비용을 함께 본다.

기존 비율의 38 특징·20 트리는 재실행 기준선 대비 macro F1 약 0.1085%p 감소로 비압축 모델 크기 94.63→25.32 MB(약 73.2% 감소), RF 추론 약 4.56 배 향상을 보였다. 반면 5 특징·100 트리는 기존 비율에서 약 118.57 MB, 균형 학습에서는 약 152.28 MB 로 커졌다. 이번 결과에서는 특징 5 개를 사용했다는 사실만으로 더 가벼운 RF 라고 할 수 없다.

판단 3. 균형 학습은 실패한 실험이 아니라 가설을 확인한 추가 검증이다.

이번 주에는 기존 RF 결과를 유지하고, 학습 불균형 완화만으로 경량화 손실이 해결되지 않았다는 결과를 함께 보고한다. 정상 오탐 감소가 최우선인 운영 조건이라면 균형군을 별도로 검토할 수 있지만, 현재 결과만으로 새로운 최적 모델이라고 선택하지 않는다. RF 결과가 MLP 양자화 손실의 원인을 설명하는 것은 아니므로 각 모델 내부의 결과로 해석한다.

검증 범위와 한계

기존 테스트를 재사용한 동일 조건 추가 검증이며 새 데이터나 새 공격에 대한 독립 평가가 아니다. 학습량을 맞췄지만 클래스 비율·정상 표본의 다양성 증가·DDoS 표본 감소가 함께 발생해 각각의 효과를 분리한 것은 아니다. 기존 세 모델의 seed 42 대조군 혼동행렬을 정확히 재현했고, 18 개 저장 모델 모두 재로딩 예측 일치를 확인했다.

크기는 비압축 RF 객체 기준이며 MLP 의 KB 단위 체크포인트 크기와 저장 형식이 다르다. 속도는 RF.predict 만 측정해 패킷 수집·특징 추출과 실제 edge 장치 지연은 포함하지 않는다. 이 보고서의 결론은 현재 데이터·분할·후보 범위에 한정한다.

자료 기준: MLP 는 제공된「mlp 양자화.pdf」원문의 문장·수치를 보존하고 순서와 표 배치를 정리했다. RF 는 기존 최종 후보·특징 수 탐색 CSV 와 완료된 18 개 균형 검증 결과를 사용했다. 보고서 작성 과정에서 새 모델 학습은 수행하지 않았다.